



# **PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL**

## **Diagnóstico de Overfitting/Underfitting**

### **Grupo 6:**

Luis Andress Bustamante Jiménez

Damaris Irene Alarcón Vallejo

**Docente:** Gladys María Villegas Rugel

10 de octubre de 2025

# Reporte Técnico

## Diagnóstico de Overfitting/Underfitting

### 1. Resumen Ejecutivo

Este informe analiza overfitting, underfitting y la generalización en modelos de aprendizaje automático, aplicando regresión logística sobre un dataset de señales cardíacas. Se usaron curvas de aprendizaje, validación y métricas como accuracy y log-loss para diagnosticar el comportamiento del modelo ante variaciones en el tamaño de entrenamiento y el hiperparámetro C. Se implementaron estrategias como regularización L2, early stopping y validación cruzada. El modelo alcanzó un rendimiento estable (accuracy ~87%, log-loss ~0.43), validando su uso como línea base, aunque con limitaciones por su linealidad. Se plantea explorar modelos más complejos, como CNNs, para abordar desafíos como el desbalance de clases y la variabilidad fisiológica en señales ECG.

### 2. Metodología utilizada

Se utilizó una regresión logística binaria con regularización L2, entrenada sobre datos divididos estratificadamente para mantener la representatividad de clases. Se analizaron curvas de aprendizaje y de validación para evaluar el impacto del tamaño de muestra y del hiperparámetro C en el rendimiento. Las métricas empleadas fueron *accuracy* y *log-loss*, esta última sensible a la calibración del modelo.

### 3. Resultados del diagnóstico

Los resultados obtenidos evidencian que el modelo de regresión logística aplicado al dataset procesado presenta un desempeño robusto y estable, sin señales marcadas de sobreajuste ni subajuste. La consistencia entre las métricas de entrenamiento y validación indica una buena capacidad de generalización, lo que lo convierte en un punto de referencia sólido para comparaciones posteriores con modelos más complejos, como redes neuronales convolucionales. Además, el análisis de hiperparámetros revela que la optimización cuidadosa de C es crítica para alcanzar el máximo rendimiento sin caer en un exceso de flexibilidad.

### 4. Análisis de curva de aprendizaje

Las curvas de aprendizaje muestran una precisión estable (~0.87) y bien calibrada (log-loss ~0.43), sin indicios de sobreajuste. La curva de validación indica que valores bajos de C generan *underfitting*, mientras que un rango entre 1 y 10 ofrece el mejor equilibrio entre sesgo y varianza. Valores muy altos de C comienzan a degradar el rendimiento por posible *overfitting*.

### 5. Estrategias implementadas y resultados

Dado que el modelo base (regresión logística) no presentó indicios de *overfitting* ni *underfitting*, las estrategias implementadas se orientaron a optimizar su rendimiento y robustez. Se trabajó en

cuatro ejes: ajuste de hiperparámetros (C y tipo de penalización), ingeniería y selección de características, validación cruzada más rigurosa (Stratified K-Fold con  $k=10$ ), y preparación para comparar con modelos más complejos.

La optimización de C y la comparación entre L1 y L2 permitió evaluar el equilibrio entre *sparsity* y estabilidad. El mejor desempeño se obtuvo con penalización L2 y  $C=1$ , lo que indica que todas las variables aportan valor al modelo y que es preferible regularlas conjuntamente. Estas acciones, aunque no responden a una falla crítica, fortalecen la confiabilidad del *baseline* y aseguran que esté bien ajustado para futuras comparaciones.

## **6. Conclusiones y recomendaciones futuras**

La regresión logística mostró un desempeño estable (accuracy  $\sim 0.87$ , log-loss  $\sim 0.43$ ) y buen equilibrio entre sesgo y varianza, posicionándose como modelo base sólido. El hiperparámetro C, en el rango 1–10, fue clave para optimizar el rendimiento. Estos resultados sirven como referencia para futuras comparaciones con modelos más complejos, como CNNs, que podrían captar mejores patrones no lineales en las señales.

## **7. Referencias técnicas**

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.). O'Reilly Media.
- Sun, C., Shrivastava, A., Singh, S., & Gupta, A. (2017). Revisiting unreasonable effectiveness of data. Proceedings of ICCV.
- Chollet, F. (2018). Deep Learning with Python. Manning Publications.