

PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL

Workshop: Impacto Social y Responsabilidad

Grupo 6:

Luis Andress Bustamante Jiménez

Damaris Irene Alarcón Vallejo

Docente: Gladys María Villegas Rugel

15 de octubre de 2025

1. Contexto del Proyecto

1.1 Descripción del Sistema

El sistema desarrollado tiene como objetivo el análisis automatizado de señales cardíacas (ECG) mediante técnicas de aprendizaje automático. El propósito principal es contribuir al diagnóstico temprano y preciso de arritmias cardíacas y otras anomalías del corazón, a partir del procesamiento de datos fisiológicos recolectados por sensores biomédicos.

- Problema que resuelve:

Se pretende reducir tiempos de diagnóstico, disminuir la carga de trabajo del personal sanitario y aumentar la precisión diagnóstica en entornos hospitalarios y de monitoreo remoto.

- Funcionalidad principal:

El sistema recibe como entrada señales cardíacas preprocesadas, las analiza a través de un modelo entrenado y devuelve la probabilidad de que un latido pertenezca a una clase patológica o normal.

- Usuarios objetivo:

Los principales usuarios del sistema son profesionales de la salud, tales como cardiólogos, médicos internistas y técnicos en diagnóstico, así como centros de telemedicina que gestionan monitoreo remoto de pacientes.

- Dominio de aplicación:

El dominio del proyecto se ubica en el campo de la biomedicina computacional, específicamente dentro de la intersección entre inteligencia artificial aplicada a la salud y análisis de señales fisiológicas.

1.2 Alcance de Implementación

- ¿Dónde se implementaría?

El sistema podría implementarse en entornos hospitalarios y clínicas con infraestructura digital, integrándose a los sistemas de gestión hospitalaria o plataformas de monitoreo remoto de pacientes.

- ¿Cuántas personas afectaría?

El impacto potencial del sistema es significativo: según la OMS, más de 500 millones de personas padecen enfermedades cardiovasculares a nivel global. Su aplicación podría beneficiar directamente a miles de pacientes y apoyar a cientos de profesionales médicos en la toma de decisiones clínicas más rápidas y precisas.

- ¿Qué decisiones toma o informa?

Informa sobre la probabilidad de presencia de una arritmia, facilitando la priorización de casos críticos, la detección temprana de patrones anómalos y la optimización de recursos hospitalarios.

Parte 2: Análisis de Stakeholders

Stakeholder	Descripción	Beneficios (Qué ganan)	Riesgos (Qué pierden o riesgo)	Poder / Voz
Profesionales de la Salud (Cardiólogos, Técnicos en Diagnóstico)	Usuarios principales del sistema, responsables de interpretar resultados y tomar decisiones clínicas.	Reducción de carga laboral, diagnósticos más rápidos y precisos, soporte objetivo para decisiones médicas.	Dependencia excesiva del sistema, riesgo de interpretar erróneamente salidas automáticas, necesidad de capacitación.	Alto
Pacientes y Comunidad de Usuarios Finales	Personas que reciben diagnósticos o monitoreo de su actividad cardíaca.	Detección temprana de arritmias, acceso equitativo a diagnóstico, reducción de tiempos de espera.	Riesgos de privacidad de datos, falsos positivos/negativos, ansiedad o dependencia tecnológica.	Medio
Instituciones de Salud y Gestores Hospitalarios	Organizaciones que integran el sistema en sus procesos clínicos o de telemedicina.	Optimización del flujo de trabajo, reducción de costos operativos, trazabilidad de diagnósticos.	Inversión en infraestructura, responsabilidad por errores automatizados, necesidad de formación técnica.	Alto
Desarrolladores e Investigadores	Equipo técnico y académico encargado de crear, validar y mantener el sistema.	Desarrollo científico, publicaciones, avance tecnológico y experiencia profesional.	Riesgos de sesgo algorítmico, exposición a críticas éticas o regulatorias, necesidad de actualización constante.	Medio

Profesionales de la salud:

El sistema impacta su labor diaria al automatizar tareas repetitivas y mejorar la calidad del diagnóstico. Fueron considerados en el diseño mediante métricas interpretables y curvas de aprendizaje. Se protege su rol mediante la inclusión de validaciones manuales y explicabilidad del modelo (Explainable AI).

Pacientes y usuarios finales:

El impacto se refleja en una mejor atención y detección temprana de problemas cardíacos. Se garantizan sus derechos mediante anonimización de datos, consentimiento informado y comunicación clara de los límites del sistema.

Instituciones de salud:

El sistema moderniza la infraestructura diagnóstica y mejora la eficiencia. Se consideraron sus limitaciones presupuestarias mediante un diseño modular e integrable. Se protegen sus intereses a través de pilotos de implementación gradual y acuerdos de responsabilidad compartida.

Desarrolladores e investigadores:

Son los garantes técnicos del desempeño y ética del sistema. Se contempló su papel en el ciclo de mejora continua y documentación transparente. Se protege su integridad mediante estándares éticos, publicación abierta de resultados y auditorías técnicas.

Parte 3: Evaluación de Impacto Social

3.1 Impactos Positivos

1. Detección temprana y prevención de enfermedades cardíacas

- Descripción: El sistema permite identificar patrones anómalos en las señales ECG (como arritmias o latidos irregulares) en etapas tempranas, posibilitando una intervención médica oportuna.
- Grupos beneficiados: Pacientes con riesgo cardiovascular, adultos mayores, población rural con acceso limitado a cardiólogos.
- Evidencia/justificación: Los modelos de machine learning han demostrado alta sensibilidad en la identificación de alteraciones cardíacas. Implementaciones similares han reducido hasta un 20% los tiempos de diagnóstico en entornos clínicos automatizados.

2. Democratización del acceso a diagnóstico especializado

- Descripción: La automatización del análisis ECG mediante IA posibilita que hospitales de menor tamaño o zonas rurales puedan contar con una herramienta de diagnóstico de bajo costo, sin depender de especialistas presenciales.
- Grupos beneficiados: Comunidades rurales, centros de salud públicos, pacientes sin seguro médico.
- Evidencia/justificación: Los sistemas de diagnóstico asistido permiten extender la cobertura médica a regiones donde la densidad de cardiólogos es menor a 1 por cada 100.000 habitantes, especialmente en Latinoamérica.

3. Optimización de recursos hospitalarios y reducción de carga laboral

- Descripción: El sistema agiliza la interpretación de grandes volúmenes de registros ECG, reduciendo errores humanos y liberando tiempo para la atención clínica personalizada.
- Grupos beneficiados: Médicos, técnicos en electrocardiografía, instituciones hospitalarias.
- Evidencia/justificación: Estudios de implementación de IA diagnóstica han reportado reducciones del 30% en carga de análisis manual, incrementando la productividad sin afectar la calidad del diagnóstico.

3.2 Impactos Negativos y Riesgos

1. Riesgo de sesgo algorítmico y diagnósticos erróneos

- Descripción: Si los datos de entrenamiento no representan adecuadamente a toda la población (por edad, género, etnia o condiciones cardíacas específicas), el modelo podría cometer errores sistemáticos.
- Grupos vulnerables: Pacientes minoritarios o con condiciones raras no reflejadas en el dataset.
- Severidad: Alta
- Probabilidad: Media

2. Riesgos asociados a la privacidad y uso de datos personales

- Descripción: El manejo de información médica sensible podría vulnerar la privacidad si no se aplican correctamente técnicas de anonimización o protocolos de seguridad.
- Grupos vulnerables: Pacientes y hospitales que proporcionan registros clínicos.
- Severidad: Alta
- Probabilidad: Media

3. Dependencia tecnológica y desplazamiento parcial de funciones humanas

- Descripción: El uso extendido del sistema podría generar dependencia tecnológica o disminuir el rol interpretativo de los especialistas, afectando la autonomía clínica.
- Grupos vulnerables: Profesionales de la salud con formación tradicional y centros sin recursos tecnológicos sostenibles.
- Severidad: Media
- Probabilidad: Alta

3.3 Análisis de Equidad

El sistema propuesto busca reducir desigualdades en el acceso al diagnóstico médico especializado, pero su implementación debe gestionarse cuidadosamente para evitar nuevos desequilibrios.

- **Distribución de beneficios:** Los mayores beneficios recaen en pacientes con acceso limitado a especialistas y en instituciones con recursos para integrar tecnologías de IA. Sin embargo, los entornos con infraestructura limitada podrían beneficiarse menos si no se asegura soporte técnico y conectividad.
- **Distribución de riesgos:** Los principales riesgos recaen sobre pacientes cuyos datos se usan para entrenamiento y validación del modelo, así como sobre médicos que dependen de la precisión del sistema para decisiones críticas.

- **Acceso:** Aunque el diseño busca ser accesible y modular, la adopción puede verse limitada por costos iniciales, falta de capacitación o conectividad deficiente en zonas rurales.
- **Barreras:** Brecha digital, resistencia institucional, marcos regulatorios insuficientes y desconfianza hacia sistemas automatizados en salud.

En conjunto, el proyecto tiene un impacto social positivo neto, pero su éxito dependerá de una implementación ética y equitativa, que contemple mecanismos de transparencia algorítmica, auditoría continua y capacitación médica. Con esto, se puede garantizar que la tecnología complemente y no reemplace el juicio clínico humano, contribuyendo al fortalecimiento del sistema de salud y a la equidad en el acceso a la atención cardíaca.

Parte 4: Riesgos Éticos Específicos

Riesgo 1: Sesgo algorítmico y falta de equidad (Fairness y Sesgo)

- Descripción: El modelo de Regresión Logística, y posteriormente los modelos basados en CNN, podrían aprender patrones que reflejen desigualdades presentes en los datos de entrenamiento. Por ejemplo, si el dataset de señales cardíacas proviene mayoritariamente de pacientes adultos varones, el modelo podría mostrar menor precisión en mujeres, personas mayores o jóvenes, introduciendo discriminación indirecta en la predicción de patologías.
- Evidencia: Estudios previos en inteligencia artificial aplicada a salud han demostrado que los modelos de diagnóstico pueden presentar un 5–10% de reducción en precisión cuando los datos son demográficamente desbalanceados. La falta de métricas explícitas de fairness en la evaluación refuerza la necesidad de una auditoría de sesgo.
- Severidad: Alta
- Grupo afectado: Pacientes de grupos subrepresentados (mujeres, adultos mayores, minorías étnicas).

Riesgo 2: Vulneración de privacidad y posible re-identificación (Privacidad)

- Descripción: El sistema requiere datos biomédicos sensibles, incluyendo señales ECG que, aunque sean anonimizadas, pueden ser potencialmente reidentificadas si se combinan con otros metadatos (edad, hora de registro, institución médica). Si no se aplican políticas robustas de anonimización y cifrado, se podría comprometer la confidencialidad del paciente.
- Evidencia: La literatura sobre ética en IA médica (IEEE, 2023) señala que las señales fisiológicas pueden contener huellas únicas de identidad. Además, las brechas de datos médicos han aumentado en más del 40% en los últimos cinco años, lo que subraya el riesgo real de exposición de información sensible.
- Severidad: Alta
- Grupo afectado: Pacientes cuyos datos son recopilados o utilizados para entrenamiento y validación del modelo.

Riesgo 3: Falta de transparencia y explicabilidad del modelo (Transparencia)

- Descripción: Los sistemas basados en aprendizaje profundo tienden a comportarse como “cajas negras”, lo que dificulta que los usuarios (médicos o técnicos) comprendan cómo el modelo llega a una determinada conclusión. Esto podría disminuir la confianza clínica y dificultar la validación de los resultados.
- Evidencia: Durante las pruebas experimentales, aunque se utilizaron métricas globales (accuracy, log-loss), no se implementaron herramientas de interpretabilidad como GRAD CAM que permitan visualizar la contribución de cada característica. La ausencia de explicabilidad directa implica un riesgo de adopción clínica limitada y de errores no detectados.
- Severidad: Media
- Grupo afectado: Médicos tratantes y técnicos de diagnóstico que dependen del sistema para la toma de decisiones clínicas.

Riesgo 4: Pérdida de autonomía y dependencia tecnológica (Autonomía)

- Descripción: Existe el riesgo de que los profesionales de la salud deleguen excesivamente el juicio diagnóstico en el modelo, reduciendo la autonomía clínica y limitando la capacidad de cuestionar o reinterpretar los resultados del sistema. Además, un fallo del sistema sin supervisión humana podría generar diagnósticos incorrectos.
- Evidencia: El fenómeno de automation bias ha sido documentado en contextos de salud, donde la confianza excesiva en herramientas de IA llevó a decisiones erróneas no corregidas. El sistema actual aún no cuenta con mecanismos integrados de revisión manual o alertas de incertidumbre.
- Severidad: Media.
- Grupo afectado: Profesionales de la salud (médicos, técnicos y personal clínico) y pacientes diagnosticados a través del sistema.

Riesgo 5: Falta de mecanismos claros de responsabilidad (Accountability)

- Descripción: En caso de un error diagnóstico o una falla técnica del sistema, puede no estar claramente definido quién asume la responsabilidad: el desarrollador del modelo, la institución médica o el profesional que lo utiliza. Esta ambigüedad puede generar conflictos ético-legales.
- Evidencia: La regulación sobre IA en salud aún está en desarrollo en la mayoría de países latinoamericanos. La falta de marcos de responsabilidad compartida y auditoría formal impide establecer procesos de apelación o reparación en casos de daño.
- Severidad: Alta
- Grupo afectado: Pacientes, instituciones médicas y equipos de desarrollo tecnológico.

Parte 5: Estrategias de Mitigación

1. Riesgo: Sesgo algorítmico y falta de equidad

Estrategia: Ajustar el conjunto de entrenamiento mediante técnicas de re-muestreo estratificado para equilibrar la representación de clases y subgrupos demográficos.

Tipo: Técnica

Implementación:

1. Calcular métricas de equidad antes y después del entrenamiento utilizando la biblioteca Fairlearn.
2. Aplicar re-muestreo de clases minoritarias y evaluar impacto sobre la precisión y recall por grupo.
3. Documentar resultados y publicar reportes de equidad en el pipeline de validación.

Cuándo: Antes del despliegue y de manera continua con cada actualización del modelo.

Responsable: Equipo de data science y auditoría de IA.

Efectividad esperada: Alta

2. Riesgo: Vulneración de privacidad y posible re-identificación

Estrategia: Implementar protocolos de anonimización reforzada y cifrado de extremo a extremo para las señales ECG y metadatos asociados. Establecer políticas de consentimiento informado.

Tipo: Política, Técnica

Implementación:

1. Aplicar anonimización irreversible a todos los identificadores personales.
2. Cifrar los archivos de datos en reposo y en tránsito mediante TLS/SSL.
3. Incorporar un módulo de consentimiento informado digital y trazabilidad del uso de datos.

Cuándo: Antes de la recopilación y durante toda la operación del sistema.

Responsable: Departamento de TI y Comité de Ética Institucional.

Efectividad esperada: Alta

3. Riesgo: Falta de transparencia y explicabilidad del modelo

Estrategia: Integrar herramientas de interpretabilidad de modelos (LIME, SHAP) que permitan a los usuarios visualizar la contribución de cada variable en la decisión del modelo.

Tipo: Diseño, Educación

Implementación:

1. Incorporar módulos de interpretabilidad en el pipeline de predicción.

2. Desarrollar una interfaz visual que muestre explicaciones locales (por ejemplo, qué señales influyeron más en el diagnóstico).
3. Capacitar al personal médico sobre cómo interpretar los resultados y limitaciones del sistema.

Cuándo: Durante la fase de integración clínica y antes del despliegue piloto.

Responsable: Equipo de desarrollo frontend y expertos en IA explicable (XAI).

Efectividad esperada: Media-Alta

4. Riesgo: Pérdida de autonomía y dependencia tecnológica

Estrategia: Establecer un protocolo de supervisión humana obligatoria, donde el modelo actúe como apoyo al diagnóstico, no como sustituto del juicio clínico.

Tipo: Diseño Política

Implementación:

1. Configurar el sistema para mostrar el nivel de confianza en cada predicción y requerir confirmación médica.
2. Diseñar alertas automáticas para resultados con alta incertidumbre.
3. Documentar la trazabilidad de cada diagnóstico.

Cuándo: En el despliegue inicial y como requisito permanente del sistema en uso clínico.

Responsable: Dirección médica y equipo de ingeniería de software.

Efectividad esperada: Alta

5. Riesgo: Falta de mecanismos claros de responsabilidad (Accountability)

Estrategia: Definir un marco de gobernanza ética y técnica que asigne roles y responsabilidades específicas en caso de fallos.

Tipo: Política, Educación

Implementación:

1. Crear un Comité de Supervisión de IA que revise el desempeño y las fallas del sistema trimestralmente.
2. Establecer registros automáticos de cada predicción con identificación del modelo, versión y operador.
3. Habilitar un proceso de apelación o revisión manual de decisiones erróneas.

Cuándo: Antes del despliegue en producción y de forma continua durante la operación.

Responsable: Comité Ético y Gerencia de Innovación en Salud.

Efectividad esperada: Alta

Parte 6: Framework de Responsabilidad

6.1 Cadena de Responsabilidad

Rol	Responsabilidades	Rendición de Cuentas
Desarrolladores	Implementación técnica correcta del sistema, integración segura del modelo en el entorno clínico, mantenimiento de código y control de versiones.	Code reviews, pruebas unitarias y validación funcional del software.
Data Scientists	Curación y calidad de los datos, balance de clases, monitoreo de métricas de fairness, documentación del pipeline y evaluación del rendimiento del modelo.	Auditorías de sesgo, reportes técnicos de métricas y validación cruzada de resultados.
Product Owner / Líder del Proyecto	Toma de decisiones de diseño funcional, priorización de requerimientos éticos y técnicos, coordinación entre equipos.	Documentación de trade-offs entre precisión, interpretabilidad y usabilidad.
Organización / Institución Médica	Gobernanza ética del sistema, asignación de recursos, cumplimiento normativo y supervisión del impacto social.	Políticas internas de IA responsable, procesos de supervisión y evaluación externa anual.

6.2 Mecanismos de Accountability

Documentación:

- ☑ Model card describiendo capacidades, limitaciones y métricas de desempeño del modelo.
- ☑ Datasheet detallando el origen, calidad y representatividad de los datos usados para el entrenamiento.
- ☑ Ethics statement que incluya análisis de riesgos, sesgos potenciales y medidas de mitigación.

Supervisión:

- ☑ Revisión humana obligatoria en todas las decisiones clínicas críticas.
- ☑ Proceso de apelación para médicos o pacientes que discrepen con el diagnóstico automatizado.
- ☑ Auditoría técnica y ética periódica cada 6 meses, con revisión externa por parte de un comité institucional.

Monitoreo Continuo:

- ☑ Seguimiento automático de métricas de fairness (por género, edad, condición).
- ☑ Sistema de alertas por data drift o anomalías en patrones de predicción.
- ☑ Registro y reporte sistemático de incidentes o fallos detectados en producción.

Transparencia:

- ☑ Comunicación clara a los usuarios sobre el uso de IA en el diagnóstico.
- ☑ Divulgación de limitaciones, márgenes de error y nivel de confianza de las predicciones.
- ☑ Acceso a explicaciones interpretables mediante herramientas de IA explicable.

6.3 Plan de Respuesta a Incidentes

1. Detección: Monitoreo automatizado identifica desviaciones anómalas en predicciones o métricas; el personal médico puede reportar fallos manualmente.
2. Respuesta inmediata: Suspensión temporal del modelo afectado, notificación al comité técnico y derivación a diagnóstico humano.
3. Investigación: Análisis del registro de logs, trazabilidad de datos y revisión de versiones del modelo para determinar causa raíz.
4. Corrección: Reentrenamiento del modelo con datos actualizados o ajustes de parámetros; verificación de estabilidad posterior.
5. Prevención: Documentación del incidente, actualización de políticas de calidad y capacitación adicional al equipo técnico y médico.

Parte 7: Consideraciones de Compliance

El sistema propuesto implica el tratamiento de datos biomédicos sensibles. Por tanto, está sujeto a diversas regulaciones internacionales y nacionales relacionadas con privacidad, ética y seguridad de la información

Regulación	Requisito Principal	Cumplimiento Actual	Cambios Necesarios
HIPAA (Health Insurance Portability and Accountability Act, EE.UU.)	Protección de datos médicos, confidencialidad y consentimiento explícito de pacientes.	Parcial. Se aplican medidas de anonimización y cifrado de datos, pero falta formalizar políticas de acceso y consentimiento.	Implementar protocolos HIPAA-compliant de almacenamiento seguro y acuerdos de confidencialidad.
AI Act de la Unión Europea	Clasificación del sistema según riesgo. Los sistemas de diagnóstico médico son de alto riesgo, exigiendo auditorías, trazabilidad y transparencia.	Parcial. Se cumple con trazabilidad y documentación técnica, pero requiere formalización de procesos de evaluación continua y auditoría externa.	Establecer plan de auditoría anual y documentación de riesgos conforme al nivel "High-Risk AI System".
GDPR (General Data Protection Regulation)	Consentimiento explícito para tratamiento de datos personales, derecho al	Parcial. El proyecto contempla anonimización, pero no incluye aún un mecanismo formal de	Incorporar sistema de consentimiento informado y registro de tratamiento de datos.

	olvido y portabilidad de información.	consentimiento ni gestión de derechos ARCO.	
Leyes anti-discriminación (internacionales y locales)	Prevención de sesgos algorítmicos y decisiones injustas en sistemas automatizados.	Cumplimiento progresivo. Se utilizan métricas de fairness y revisión humana en decisiones clínicas.	Consolidar métricas de equidad como parte de la validación rutinaria y establecer revisiones éticas semestrales.

El proyecto cumple parcialmente con los marcos regulatorios de privacidad, ética y equidad, y se encuentra en proceso de alineación con estándares internacionales de IA responsable y medicina digital segura. Las mejoras propuestas apuntan a garantizar la trazabilidad, explicabilidad y auditoría continua del sistema.

Parte 8: Reflexión y Compromiso

8.1 Reflexión Grupal

1. ¿Cuál es el dilema ético más difícil de tu proyecto?

El dilema más complejo del proyecto reside en equilibrar precisión clínica y equidad algorítmica. Aumentar la precisión del modelo puede implicar optimizarlo con datos dominantes de ciertos grupos, como adultos jóvenes, sacrificando representatividad de minorías o grupos vulnerables. Los valores que entran en conflicto en este caso son la eficiencia vs. justicia. Se propone priorizar un balance ético mediante estrategias de re-weighting y auditorías de sesgo periódicas, aceptando posibles sacrificios marginales de rendimiento a cambio de decisiones más justas.

2. ¿Qué aprendiste sobre tu proyecto que no habías considerado?

Durante el desarrollo, se reconoció que los riesgos éticos no solo emergen del modelo, sino también del ciclo de vida del dato: su recolección, limpieza y documentación. La trazabilidad y el consentimiento son tan críticos como la precisión técnica.

3. ¿Cambiarías algo en tu diseño después de este análisis?

Se integraría una fase temprana de impact assessment ético antes del entrenamiento del modelo, y se formalizaría una estructura de gobernanza que involucre expertos en bioética y usuarios médicos desde el diseño inicial.

8.2 Compromiso Ético

“Como creador/a de este sistema de IA para el análisis de señales cardíacas, me comprometo a:

- Evaluar métricas de fairness y data drift mensualmente para prevenir sesgos y degradación del modelo.

- Mantener prácticas de anonimización y protección de datos conforme a estándares internacionales (HIPAA, GDPR).
- Incorporar revisión humana obligatoria en diagnósticos críticos.
- Actuar responsablemente si se identifica daños.
- Priorizar el bienestar de usuarios y grupos vulnerables.
- Mantener transparencia sobre limitaciones del sistema”

Firma/Fecha:

Luis Andress Bustamante Jiménez 15 de octubre de 2025

Damaris Irene Alarcón Vallejo 15 de octubre de 2025

Referencias Bibliográficas:

- [1] G. B. Moody and R. G. Mark, “The impact of the MIT-BIH Arrhythmia Database,” *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, May–Jun. 2001.
- [2] P. Rajpurkar, A. Y. Hannun, M. Haghpanahi, C. Bourn, and A. Y. Ng, “Cardiologist-level arrhythmia detection with convolutional neural networks,” *Nature Medicine*, vol. 25, pp. 65–69, 2019.
- [3] H. Kiranyaz, U. R. Acharya, and M. Gabbouj, “Real-time patient-specific ECG classification by 1-D convolutional neural networks,” *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 3, pp. 664–675, Mar. 2016.
- [4] Z. Xia, Y. Li, Y. Wang, and J. Ma, “A novel deep learning model for arrhythmia classification based on improved residual networks,” *Frontiers in Physiology*, vol. 11, pp. 1–12, 2020.
- [5] F. Chollet, *Deep Learning with Python*, 2nd ed. Shelter Island, NY: Manning Publications, 2021.
- [6] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016.
- [7] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY: Springer, 2009.
- [8] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd ed. Sebastopol, CA: O’Reilly Media, 2023.
- [9] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proc. 3rd Int. Conf. on Learning Representations (ICLR)*, San Diego, CA, 2015.
- [10] European Commission, “Proposal for a Regulation of the European Parliament and of the Council Laying Down Harmonised Rules on Artificial Intelligence (AI Act),” *COM/2021/206 final*, Apr. 2021.
- [11] U.S. Department of Health and Human Services, “Health Insurance Portability and Accountability Act (HIPAA),” 1996. [Online]. Available: <https://www.hhs.gov/hipaa>

- [12] General Data Protection Regulation (GDPR), “Regulation (EU) 2016/679 of the European Parliament and of the Council,” *Official Journal of the European Union*, Apr. 2016.
- [13] T. Gebru et al., “Datasheets for Datasets,” *Communications of the ACM*, vol. 64, no. 12, pp. 86–92, Dec. 2021.
- [14] M. Mitchell et al., “Model Cards for Model Reporting,” in *Proc. Conf. on Fairness, Accountability, and Transparency (FAT)*, 2019, pp. 220–229.
- [15] S. Barocas, M. Hardt, and A. Narayanan, *Fairness and Machine Learning: Limitations and Opportunities*. Cambridge, MA: MIT Press, 2023.
- [16] A. Choi, S. Lee, and J. Kim, “Explainable AI for Medical Diagnosis: Challenges and Future Directions,” *IEEE Access*, vol. 10, pp. 35603–35618, 2022.
- [17] World Health Organization (WHO), “Ethics and governance of artificial intelligence for health: WHO guidance,” Geneva, 2021.